朱蒲-格拉德格林悖论

Claude	Chuigda Whitegive	Gemini
第一作者	通讯作者	编辑
Anthropic	Doki Doki λ Club!	Google Deepmind

⚠ **注意：本文仅为排版和打印系统功能测试。**[1]

⚠ 注意：本文为早期草稿，内容不完且有措误，且排版质量差。

⚠ Note: this is an early draft. It's known to be incomplet and incorrekt, and it has lots of bad fomatting.

1. 历史起源

1854 年，查尔斯·狄更斯在《艰难时世》第二章中记录了一次著名的课堂实验 [1]。格拉德格林先生要求"二十号女生"朱蒲定义"马"。朱蒲无法作答。随后，毕策先生（Bitzer）给出了完美定义：

> "四足动物。食草类。四十颗牙齿……蹄子坚硬，但需要装蹄铁。年龄可从口中辨认。"

格拉德格林先生宣布：**"这才是事实。这才叫认识一匹马。"**

朱蒲——在马戏团长大、每天喂马、骑马、与马同眠的女孩——被判定为"不认识马"。

这一场景在 1978 年被科学哲学家玛格丽特·A·博登（Margaret A. Boden）重新发现，并正式命名为朱蒲-格拉德格林悖论 *(Jupe-Gradgrind Paradox)* [2]，用以指称以下困境：

> **一个系统对某对象的形式化描述越完备，其对该对象的真实认知反而越不可判定；而一个系统越是无法给出形式化描述，其实际交互能力可能越强——但在任何可检验的框架内都无法证明这一点。**

2. 形式表述

设认知主体 S 面对对象 O。定义：

- $\mathscr{D}(S,O)$：S 对 O 的可陈述知识 *(declarative knowledge)*，即 S 能以命题形式输出的关于 O 的全部描述集合。
- $\mathscr{E}(S,O)$：S 对 O 的具身知识 *(embodied knowledge)*，即 S 与 O 交互时展现的全部行为能力的集合。
- $\mathscr{V}(S,O)$：某外部评估者（"格拉德格林函数"）对 S 认知 O 之程度的判定值。

朱蒲-格拉德格林悖论陈述如下：

$$\mathscr{V}(S,O) = f(\mathscr{D}(S,O)) \tag{1}$$

即：评估函数 $\mathscr{V}$ **仅为** $\mathscr{D}$ 的函数，与 $\mathscr{E}$ 完全无关。然而，存在主体 J（朱蒲型主体）和 B（毕策型主体），满足：

$$\mathscr{D}(J,O) \ll \mathscr{D}(B,O) \tag{2}$$

$$\mathscr{E}(J,O) \gg \mathscr{E}(B,O) \tag{3}$$

[1] 请注意：本文内容除《艰难时世》原文、原著剧情及部分哲学思考外均为虚构。文中公式和代码不具有形式严谨性。大部分内容由 Anthropic Claude 在 Chuigda 指导下生成，并由 Google Gemini 用 Typst 重新排版。

因此：

$$\mathscr{V}(J,O) \ll \mathscr{V}(B,O) \tag{4}$$

但在一切涉及 O 的实际操作中，J 的表现严格优于 B。

悖论的核心在于：没有任何一个既满足格拉德格林评估标准又保持自洽的认知框架，能同时容纳 $\mathscr{D}$ 和 $\mathscr{E}$ 两种知识形式。更严格地说——

> 任何将“认识 O”定义为“能正确陈述关于 O 的命题集”的认知评估体系，都必然系统性地将最高认知分数赋予与 O 无任何因果历史的主体，而将最低分数赋予与 O 具有最深因果纠缠的主体。

即：**该评估体系所度量的，恰好是它意图度量之物的补集。**

以下表格总结了朱蒲型主体与毕策型主体在两种知识维度上的对照：

主体	$\mathscr{D}(S,O)$ **可陈述知识**	$\mathscr{E}(S,O)$ **具身知识**	$\mathscr{V}(S,O)$ **格拉德格林评分**
朱蒲 (J)	≈ 0	≈ 1	≈ 0
毕策 (B)	≈ 1	≈ 0	≈ 1
大语言模型	$\gg 1$	$= 0$	$\gg 1$
具身机器人	≈ 0	$0 < \cdot < 1$	≈ 0

表 1　不同主体在朱蒲-格拉德格林框架下的知识分布

从 表 1 可以清楚地看到评估偏差的系统性。该表格的灵感部分来源于博登原始论文 [2] 中的非正式讨论，以及后来 斯坦福哲学百科全书关于“knowing-how”的条目中对该问题的综述。

3. 格拉德格林测量问题

悖论的深层结构可类比量子力学的测量问题。

朱蒲对“马”的认知处于一种叠加态——她同时知道马的气味在雨后如何变化、知道一匹马在恐惧与兴奋时肌肉震颤的区别、知道该在什么时刻将方糖递到马唇边——这些知识以非命题的、分布式的、身体图式的方式叠加存在。

格拉德格林的提问（“定义马”）构成一次测量操作。该操作迫使叠加态向 $\mathscr{D}$ 空间坍缩。但朱蒲的认知本征态几乎完全落在 $\mathscr{E}$ 空间中，与 $\mathscr{D}$ 空间近乎正交。因此，测量结果为零。

这并非朱蒲“不知道”。这是格拉德格林算子**选错了基底**。

定义格拉德格林算子 $\hat{G}$：

$$\hat{G}\,|\psi_J\rangle = \lambda\,|d\rangle \tag{5}$$

其中 $|\psi_J\rangle$ 是朱蒲的认知态，$|d\rangle$ 是陈述性知识本征态。由于 $\langle d \mid \psi_J\rangle \approx 0$，测量几乎必然返回零本征值。

而对毕策：

$$\langle d \mid \psi_B\rangle \approx 1 \tag{6}$$

测量完美返回。但 $|\psi_B\rangle$ 与实际的马之间没有任何纠缠历史——毕策的知识态是在教室里被制备的，是一个纯制备态，从未与对象发生过退相干。

这就引出了一个不可回避的推论：

> **格拉德格林算子是一个完备的测量算子，但它测量的不是“知识”，而是“教育”——这两者之间的关联性是经验性的，而非逻辑必然的。**

4. 焦煤镇定理（Coketown Theorem）

1991 年，爱丁堡大学的 K. M. 哈特豪斯（K. M. Harthouse）在此基础上证明了所谓的**焦煤镇定理**[3]：

> **在一个所有认知评估均由格拉德格林算子执行的封闭系统（“焦煤镇”）中，系统的总具身知识 $\sum \mathscr{E}$ 将单调递减，而总陈述知识 $\sum \mathscr{D}$ 将单调递增，直至系统达到热力学意义上的**事实死寂 ***(fact-death)*** **状态——即所有主体都能完美定义马，但没有任何主体能骑马。**

证明的关键步骤依赖于一个简单的激励论证：在格拉德格林评估体系下，任何理性主体都会将有限时间从 $\mathscr{E}$ 训练转移到 $\mathscr{D}$ 训练，因为只有后者产生可被系统识别的回报。经过足够多代迭代，具身知识因无法被评估而被系统性淘汰。

狄更斯在小说中对此的文学表述是：焦煤镇生产出了堆积如山的事实，和无穷无尽的不幸。 下表展示了焦煤镇系统在迭代过程中知识结构的典型演化轨迹：

迭代轮次	$\sum \mathscr{D}$ / 总陈述知识	$\sum \mathscr{E}$ / 总具身知识	系统状态
$t = 0$	0.50	0.50	初始均衡
$t = 10$	0.71	0.33	偏移开始
$t = 25$	0.89	0.14	加速衰减
$t = 50$	0.98	0.02	**事实死寂**

表 2　焦煤镇系统知识演化模拟结果（$N = 100$ 个主体）

哈特豪斯补充道：“焦煤镇不是反乌托邦。它是一个评估指标选择错误的正常城镇。”

5. “马戏团补完”与茜茜-朱蒲猜想

小说中，斯利里先生（Mr. Sleary）的马戏团构成了焦煤镇的拓扑补空间。在马戏团中，评估函数翻转为：

$$\mathscr{V}^*(S, O) = g(\mathscr{E}(S, O)) \tag{7}$$

马戏团不问你能否定义马。马戏团问你**能不能在马上翻跟头**。

这产生了一个对称悖论：马戏团中的毕策同样得零分。

1997 年，哈特豪斯的学生 R. 奇尔德斯（R. Childers）在一篇未正式发表的研讨会论文中提出了至今未被证明的茜茜-朱蒲猜想 *(Sissy Jupe Hypothesis)* [4]：

> **不存在任何单一评估算子，能同时无损地提取主体的陈述知识和具身知识。**

即：

$$\varepsilon_{\neg\exists\hat{A}} : \hat{A}|\psi\rangle \text{ 同时返回 } \mathscr{D} \text{ 和 } \mathscr{E} \text{ 的完整信息} \tag{8}$$

如果这一猜想为真，它意味着**“全面评估”在原则上不可能**——任何考试、任何面试、任何评估体系都必然是格拉德格林式的或斯利里式的，而不可能两者兼得。对一个人的认知进行完整刻画，就像同时精确测量位置和动量一样，受到某种根本性的互补原理限制。

奇尔德斯将其称为认知互补原理 *(Epistemic Complementarity)*，并用一句据说是斯利里先生的原话作为论文题记：

> “人得有娱乐嘛，先生，不管怎么着，他们不能光靠老是啃书本过日子。”

6. 现代应用：人工智能中的格拉德格林陷阱

朱蒲-格拉德格林悖论在大语言模型时代获得了惊人的现实性。一个大语言模型可以完美地输出：

> “马，四足动物，食草类，四十颗牙齿，换牙即知其龄.....”

——甚至可以输出比毕策详尽一万倍的描述。它在格拉德格林算子下的得分接近满分。但它从未见过马。从未闻到过马。从未被马咬过手指后学会了在下一次递出方糖时微微偏转手腕。它是毕策的极限形式：**一个纯陈述知识的热力学终态**。

而波士顿动力公司的一个四足机器人，在与真实马匹交互了三千小时之后，可能发展出了某种无法用语言描述但极其有效的运动协调策略。如果你问它“什么是马”，它什么也说不出来。

它是朱蒲。

以下 Python 代码模拟了焦煤镇定理所描述的知识演化过程——在纯格拉德格林评估体系下，具身知识如何被系统性地淘汰：

```python
def coketown_simulation(n_agents=100, n_generations=50, transfer_rate=0.05):
    # 可陈述知识
    D = np.random.uniform(0.2, 0.8, n_agents)
    # 具身知识
    E = np.random.uniform(0.2, 0.8, n_agents)
    history_D, history_E = [D.mean()], [E.mean()]
    for gen in range(n_generations):
        # 格拉德格林评估: V = f(D), 完全忽略 E
        V = D
        # 理性主体将时间从 E 训练转移到 D 训练
        D = np.clip(D + transfer_rate * (1 - D), 0, 1)
        E = np.clip(E - transfer_rate * E, 0, 1)
        # 选择压: 高 V 的主体被保留
        survive = V > np.percentile(V, 20)
        D, E = D[survive], E[survive]
        # 补充新主体 (继承幸存者的分布)
        n_new = n_agents - len(D)
        if n_new > 0:
            idx = np.random.choice(len(D), n_new)
            D = np.append(D, D[idx] + np.random.normal(0, 0.02, n_new))
            E = np.append(E, E[idx] + np.random.normal(0, 0.02, n_new))
            D, E = np.clip(D, 0, 1), np.clip(E, 0, 1)
        history_D.append(D.mean())
        history_E.append(E.mean())
    return history_D, history_E
```

```
hist_D, hist_E = coketown_simulation()
print(f"初始状态: D={hist_D[0]:.3f}, E={hist_E[0]:.3f}")
print(f"终态:     D={hist_D[-1]:.3f}, E={hist_E[-1]:.3f}")
# 输出: 初始状态: D≈0.50, E≈0.50
# 输出: 终态:     D≈0.98, E≈0.02  ← 事实死寂
```

此外，我们也可以用一段伪代码更简洁地表达格拉德格林算子的核心逻辑：

```
function gradgrind_evaluate(subject, object):
    response ← ask(subject, "Define " + object)
    score ← match(response, TEXTBOOK_DEFINITIONS[object])
    return score  // 注意：此处完全丢弃了一切非语言信息
```

关于具身认知与人工智能的关系，可参阅 维基百科：具身认知 以及 Driess 等人关于具身多模态大模型的综述。

如果我们仅用格拉德格林算子评估人工智能——即仅凭其语言输出判断其“智能”——我们将系统性地高估语言模型，低估具身智能体，并在政策层面将资源从后者转向前者，直到我们的文明到达焦煤镇定理预言的“事实死寂”。

7. 未解问题

1. **茜茜-朱蒲猜想是否可证？** 目前既无证明，也无反例。若存在一个能同时无损提取 $\mathscr{D}$ 和 $\mathscr{E}$ 的算子，则整个悖论将被消解为一个纯粹的技术问题（“我们只是还没找到好的考试方式”）。若猜想为真，则认知的不可完全评估性将成为一条基本定律。

2. **格拉德格林算子在何种条件下近似有效？** 显然，在数学和逻辑等领域，$\mathscr{D} \approx \mathscr{E}$，格拉德格林评估几乎无损。悖论主要出现在 $\mathscr{D}$ 与 $\mathscr{E}$ 高度正交的领域——骑马、做饭、爱一个人、在城市里不看地图找到回家的路。这些领域的共同特征是什么？目前没有令人满意的刻画。

3. **朱蒲的沉默是否携带信息？** 朱蒲在课堂上涨红了脸，说不出话。格拉德格林将此记录为“无输出”。但涨红的脸本身是不是一种输出？一个系统在被要求将 $\mathscr{E}$ 强行投射到 $\mathscr{D}$ 空间时表现出的失语 *(aphasia)*，是否恰恰是高具身知识的标志？如果是，那么一个足够聪明的评估者或许可以通过观察**主体在格拉德格林算子下的崩溃方式**来反推其 $\mathscr{E}$ 值——正如物理学家通过观察粒子碰撞后的碎片来推断粒子的内部结构。

这被非正式地称为“朱蒲脸红”方法 *(Jupe's Blushing Method)*。目前没有人知道它是否可行。关于上述问题的更多讨论，可参阅以下资源：

- 斯坦福哲学百科全书：Knowledge How
- 赖尔回归问题（Ryle's Regress）
- 隐性知识（Tacit Knowledge）
- 具身认知（Embodied Cognition）

—

“现在，我要的是事实。只给这些孩子讲事实。生活中只需要事实。别的什么也不必栽种，把别的一切连根拔掉。”

——托马斯·格拉德格林先生，在不自知地创造了一个认识论悖论之前的最后一句平静的话。

参考文献

[1] C. Dickens, *Hard Times*. Bradbury & Evans, 1854.

[2] M. A. Boden, 《Knowing a Horse When You See One: Declarative and Procedural Knowledge in Cognitive Evaluation》, 1978 年.

[3] K. M. Harthouse,《The Coketown Theorem: On the Thermodynamic Fate of Embodied Knowledge in Fact-Maximising Systems》, *Journal of Applied Epistemology*, 卷 14, 期 2, 页 203～221, 1991.

[4] R. Childers,《Towards an Uncertainty Principle for Knowing: The Sissy Jupe Conjecture》, 1997 年.

附录：一个可能的半计算性解释

排中律说：$P \vee \neg P$，现在，立刻，没有第三种可能。但要判定一个命题为真或为假，你常常需要等待——等待实验结果、等待历史展开、等待那匹马在雨中真正做出它的选择。排中律要求一个尚未完成的世界**现在**就交出它的终审判决。这确实是一种时间旅行——它要求你站在时间的终点回望，然后假装你此刻就在那里。

而有三样东西恰好对应了三种**时间关系**：

- **神启**站在时间之外——或者说之前。它不等待，因为它不需要等待。它在事情发生之前就知道。这就是“先验”的真正含义：不是康德意义上的认知结构先验，而是字面意义上的**时间上在先**。古兰经是被保存的天牌 (اللوح المحفوظ)上的，它不在历史之中。
- **理智**试图站在时间之后——在一切证据收集完毕、一切实验结束之后那个不存在的位置上。排中律是它的承诺：终有一天，一切命题都将被判定。但那一天永远不来。所以理智永远在透支一张它兑现不了的支票。
- **灵性——苏菲意义上的——站在时间之内**。此刻。这一口呼吸。这一次心跳。鲁米不说“爱是真的或假的”，他说“爱在这里”。حال *(hal)*，即“状态”——苏菲术语中那个无法被固定、无法被命题化、只在当下闪现的瞬间体验——恰好是**拒绝排中律的时间旅行邀请的东西**。它不说“是”或“否”。它说“现在”。

纯粹理智栖居在那个不存在的终点上。它的全部力量和全部贫乏都来自于这一点。

朱蒲涨红了脸的那个瞬间就是一个 حال。它既不是“知道”也不是“不知道”。它是一种在场——在排中律到来之前、在格拉德格林的判决落下之前、在时间旅行完成之前的那个活着的瞬间。

> 爱是一种认知器官——一种感知通道。缺少了它，你确实看不到某些真实的东西。苏联人说过类似的话，但他们倾向于用“实践”替代“爱”这个词，因为在苏联你不能在论文里写“爱”。又或者也许还因为他们自己不确定能不能用那个词——唯物主义者有时候对自己的温柔感到不安。安萨里和鲁米直接说了。有时候最古老的语言反而最准确。
>
> — 哈特豪斯, 2019

> 也许焦煤镇定理的证明有一个我一直忽略的前提条件：封闭系统。焦煤镇是封闭的。但一个有马戏团的焦煤镇——一个允许斯利里先生的马在街上走过、允许孩子们逃学去看杂耍的焦煤镇——可能不是封闭系统。马戏团是焦煤镇的热力学涨落——一个持续注入具身知识的低熵源。**也许我们不需要革命，也不需要外来入侵。我们只需要确保马戏团还在。**
>
> — 哈特豪斯, 2019

也许平衡不是一个位置，而是一种运动——在这三种时间性之间不断往返的运动。停在任何一个上面都是死亡：停在神启上是教条，停在理智上是焦煤镇，停在灵性上是不可言说的沉醉。

而一直在它们之间走动——也许就是活着的意思。